# Analyse exploratoire pour une expansion internationale

## Présentation

**Academy**

# Plan du projet

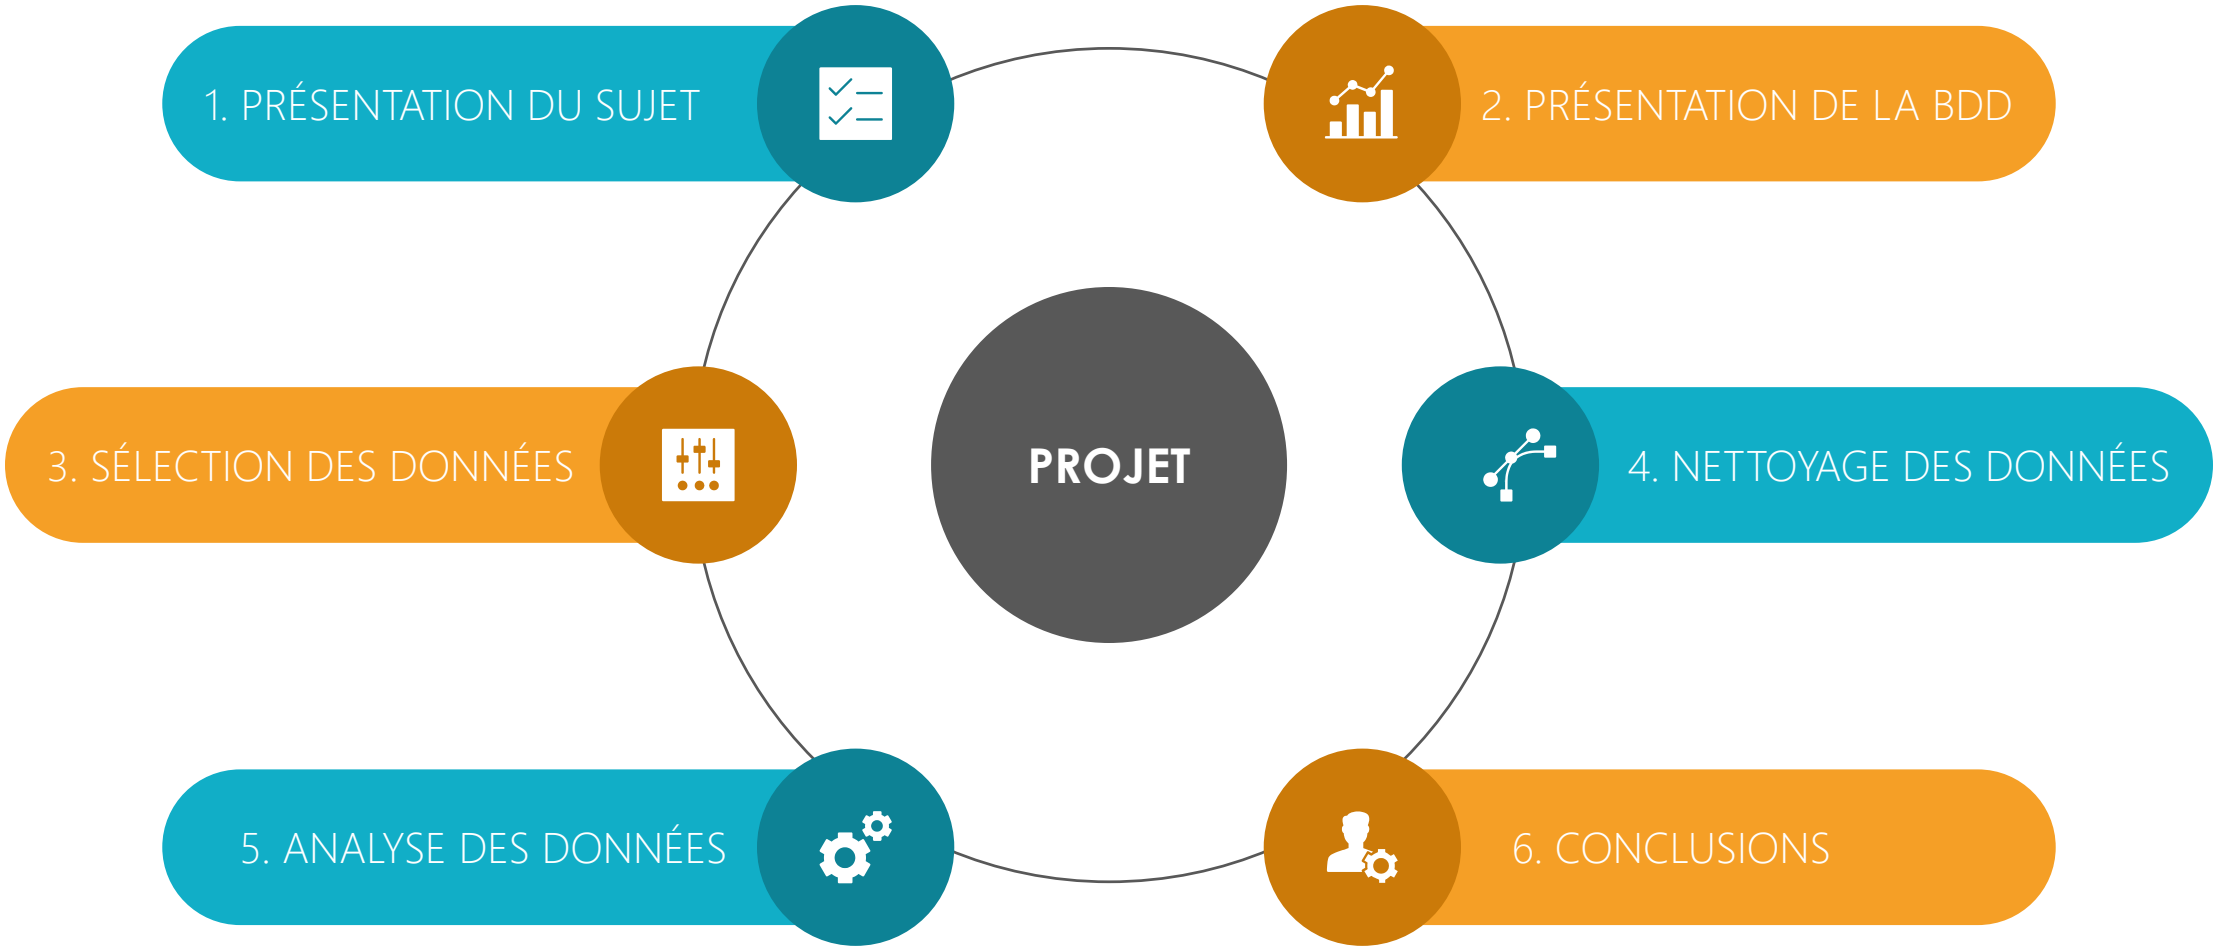

# Présentation du Sujet

## ENTREPRISE

Academy, une start-up spécialisée dans la formation en ligne pour lycéens et universitaires

## CONTEXTE

L'entreprise cherche à identifier les pays à fort potentiel d'expansion pour y développer ses solutions

## OBJECTIF

Utiliser les données éducatives mondiales pour guider la stratégie d'internationalisation d'Academy

## OPPORTUNITÉ

Les évolutions dans l'éducation offrent des nouvelles opportunités d'accès à des marchés émergents

## MISSION

Mener une analyse exploratoire et fournir des recommandations basées sur les données fournies

# Présentation de la BDD

**Indicateurs disponibles**
Plus de 4 000 indicateurs couvrant l'accès à l'éducation, la progression, les enseignants, les dépenses et la population

**Couverture globale**
Cycle éducatif complet : de la maternelle à l'enseignement tertiaire complet

**Évaluations et projections**
Résultats d'évaluations internationales (PISA, TIMSS, PIRLS) données d'équité et projections jusqu'en 2100

**Utilité pour Academy**
Des données précises pour identifier les opportunités dans les marchés émergents et avancés

# Présentation de la BDD

| Noms des Jeux de Données | Data | Country | Series | Country-Series | FootNote |
|---|---|---|---|---|---|
| **Cellules vides** | 53 455 179 | 2 354 | 55 203 | 613 | 643 638 |
| **Lignes** | 886 930 | 241 | 3 665 | 613 | 643 638 |
| **Colonnes** | 70 | 32 | 21 | 4 | 5 |
| **Colonnes algébriques** | 4 | 28 | 15 | 3 | 4 |
| **Colonnes numériques** | 66 | 4 | 6 | 1 | 1 |
| **Description** | Contient les données brutes récoltées, avec en ligne les indicateurs par pays, et en colonne les années | Contient la liste de tous les pays et régions de la base de données, avec les informations sur la récolte des données | Présente les différents indicateurs avec leurs sources, leurs descriptions, et leurs unités de mesure notamment | Associe les couples pays/indicateur, et mentionne les sources des données, spécifiques à chaque couple | Associe les couples pays/indicateur, et en fait une brève description |

# Sélection des données

Contient un jeu d'indicateurs renseignant sur les services éducatifs internationaux

Données de la Banque Mondiale

Souhaite trouver des pays à fort potentiel pour proposer ses services adressés aux lycéens et universitaires

Academy

Objectifs

Trouver des indicateurs indiquant une demande potentielle pour les services éducatifs

Indicateurs

Ceux-ci devront répondre au maximum aux besoins et spécifications des services et cibles d'Academy

Économiques

L'économie et la politique du pays en matière d'éducation doit être propice au développement de solutions EdTech

Démographiques

Le taux de scolarisation ou le nombre d'étudiants pourraient faciliter l'implantation d'Academy

Technologiques

Le développement technologique est un paramètre clé pour le déploiement de services connectés

# Sélection des données

**Suppression des lignes vides**

Initialement 886 930 lignes, réduites à 357 405 après suppression des données incomplètes

**Tri des indicateurs par effectifs**

Classement des indicateurs par fréquence pour identifier les plus représentatifs et exploitables

**Exclusion des indicateurs non pertinents**

Filtrage des niveaux éducatifs et exclusion des genres spécifiques

**Sélection des indicateurs finaux**

Conservation des indicateurs pertinents pour le lycée et l'université

# Sélection des données

| Indicateurs | Description |
|---|---|
| Internet users (per 100 people) | Indicateur clé pour l'accès aux services en ligne, car plus le taux d'utilisateurs d'Internet est élevé, plus le potentiel pour l'éducation en ligne est grand. |
| GNI, PPP (current international $) | Le revenu national brut (ajusté en parité de pouvoir d'achat) indique le niveau de richesse du pays et sa capacité à dépenser pour des services éducatifs. |
| Gross enrolment ratio, upper secondary, both sexes (%) | Permet de voir le taux de scolarisation dans le secondaire, qui est une des cibles principales d'academy. |
| Gross enrolment ratio, tertiary, both sexes (%) | Indique l'accès à l'enseignement supérieur, qui est un marché potentiel pour academy. |
| Personal computers (per 100 people) | Comme pour l'accès à Internet, cet indicateur aide à mesurer l'accès aux technologies nécessaires pour les cours en ligne. |
| Percentage of enrolment in upper secondary education in private institutions (%) | Donne une idée du développement du secteur privé dans l'éducation, ce qui pourrait être un indicateur de marché pour des formations en ligne payantes. |
| Percentage of enrolment in tertiary education in private institutions (%) | Indicateur similaire au précédent mais pour le supérieur, montrant la propension à payer pour l'éducation dans ce pays. |
| Government expenditure on education as % of GDP (%) | Donne une idée de l'engagement du gouvernement envers l'éducation, un facteur important pour l'infrastructure éducative. |
| Government expenditure on tertiary education as % of GDP (%) | Permet de voir l'investissement public dans l'enseignement supérieur. |
| Government expenditure on secondary education as % of GDP (%) | Similaire au précédent, mais pour le secondaire, pour comprendre le soutien gouvernemental dans les niveaux ciblés par academy. |
| Expenditure on education as % of total government expenditure (%) | Mesure le poids de l'éducation dans le budget global du gouvernement, ce qui indique les priorités nationales. |
| Government expenditure per upper secondary student (PPP$) | Indique les ressources allouées par étudiant dans le secondaire, montrant l'investissement éducatif pour ce niveau. |
| Government expenditure per tertiary student (PPP$) | Idem pour le supérieur, ce qui peut être un indicateur de la qualité de l'enseignement supérieur dans le pays. |

# Filtrage des années pertinentes

- **Sélection des années avec le plus de données :** Choix porté sur les années 1999 à 2013, qui contiennent le moins de valeurs manquantes pour une base solide d'analyse.
- **Projections éducatives :** Inclusion des années 2014 à 2016 pour explorer les investissements futurs dans l'éducation
- **Limites des données de projection :** Les projections après 2016 manquent de données , nécessitant des estimations pour des prévisions jusqu'en 2030.
- **Conclusion :** Étude des indicateurs sur la période 1999-2016, avec des projections estimées jusqu'en 2030.

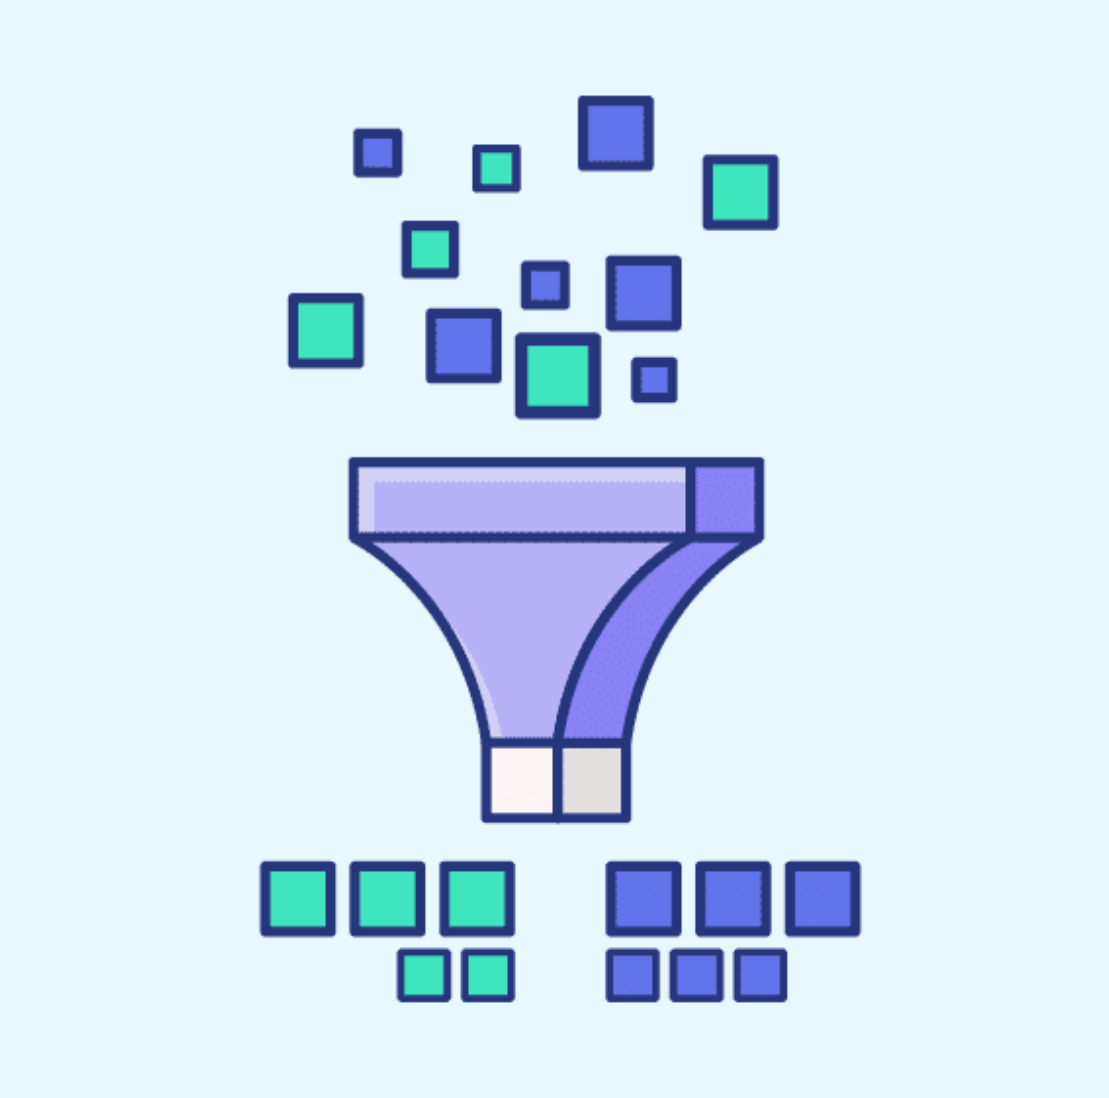

Source : datascientest.com

# Réorganisation des données

- **Objectif :** Réorganiser les données pour une analyse facilitée, avec les pays en lignes et les indicateurs en colonnes.
- **Code utilisé :** Création d'un pivot_table pour chaque année étudiée, avec les indicateurs comme colonnes et les valeurs correspondantes.
- **Structure obtenue :** Un Dataframe par année, permettant une exploration précise et cohérente des données.

Exemple de Dataframe obtenu pour l'année 2009

| Country Name | Expenditure on education as % of total government expenditure (%) | GNI, PPP (current international $) | Government expenditure on education as % of GDP (%) | Government expenditure on secondary education as % of GDP (%) | Government expenditure on tertiary education as % of GDP (%) | Government expenditure per tertiary student (PPP$) | Government expenditure per upper secondary student (PPP$) | Gross enrolment ratio, tertiary, both sexes (%) | Gross enrolment ratio, upper secondary, both sexes (%) | Internet users (per 100 people) | Percentage of enrolment in tertiary education in private institutions (%) | Percentage of enrolment in upper secondary education in private institutions (%) |
|---|---|---|---|---|---|---|---|---|---|---|---|---|
| Afghanistan | NaN | 4.168437e+10 | NaN | NaN | NaN | NaN | NaN | 3.903390 | 26.050900 | 3.55 | NaN | NaN |
| Albania | NaN | 2.542120e+10 | NaN | NaN | NaN | NaN | NaN | 33.400749 | 72.855003 | 41.20 | 14.32697 | 8.80628 |
| Algeria | NaN | 4.300245e+11 | NaN | NaN | NaN | NaN | NaN | 29.818720 | 49.466370 | 11.23 | NaN | 0.25024 |
| Andorra | NaN | NaN | 3.16387 | 0.82665 | 0.11384 | NaN | NaN | NaN | NaN | 78.53 | NaN | 2.28471 |
| Angola | NaN | 1.172989e+11 | NaN | NaN | NaN | NaN | NaN | NaN | 19.258320 | 2.30 | NaN | 10.12886 |

# Nettoyage des données

### Dimensions des Dataframes

Uniformisation des tableaux par nombre de pays et d'indicateurs.

Les Dataframes par années doivent contenir 14 colonnes et 237 pays.

### Ajout des valeurs manquantes

Estimation des valeurs manquantes par régression linéaire en fonction des valeurs des années disponibles pour chaque pays

Modèle naïf si une seule valeur disponible

### Vérification des doublons

Les Dataframes ne doivent contenir aucun doublon pour ne pas perturber les analyses.

Le jeu de données de la Banque Mondiale ne contient aucun doublon.

### Vérification des types de données

Afin de pouvoir les utiliser postérieurement, les données des colonnes devront être numériques.

Toutes les colonnes contiennent bien des flottants.

### Traitement des valeurs aberrantes

Les estimations par régression linéaire ont pu donner des valeurs aberrantes (pourcentages négatifs ou >100)

Des bornes ont donc été créées

# Nettoyage des données

**Modèle d'estimation par régression linéaire : L'exemple de l'Albanie**

Avant estimation :

| | Year | Country Name | Expenditure on education as % of total government expenditure (%) | GNI, PPP (current international $) | Government expenditure on education as % of GDP (%) | Government expenditure on secondary education as % of GDP (%) | Government expenditure on tertiary education as % of GDP (%) | Government expenditure per tertiary student (PPP$) | Government expenditure per upper secondary student (PPP$) | Gross enrolment ratio, tertiary, both sexes (%) | Gross enrolment ratio, upper secondary, both sexes (%) | Internet users (per 100 people) | Percentage of enrolment in tertiary education in private institutions (%) |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| **0** | 1999 | Albania | 9.68246 | 1.172813e+10 | 3.37669 | NaN | NaN | NaN | NaN | 14.805040 | 42.998322 | 0.081437 | NaN |
| **237** | 2000 | Albania | 10.13703 | 1.280375e+10 | 3.28719 | NaN | NaN | NaN | NaN | 15.603730 | 43.697090 | 0.114097 | NaN |
| **475** | 2001 | Albania | 10.58193 | 1.408616e+10 | 3.34271 | NaN | NaN | NaN | NaN | 15.974960 | 45.356331 | 0.325798 | NaN |
| **712** | 2002 | Albania | 9.88692 | 1.486245e+10 | 3.05522 | NaN | NaN | NaN | NaN | 16.431709 | 48.959530 | 0.390081 | NaN |
| **949** | 2003 | Albania | 10.57360 | 1.597008e+10 | 3.06470 | NaN | NaN | NaN | NaN | 16.805559 | 51.771450 | 0.971900 | 0.0 |

Après estimation :

| | Year | Country Name | Expenditure on education as % of total government expenditure (%) | GNI, PPP (current international $) | Government expenditure on education as % of GDP (%) | Government expenditure on secondary education as % of GDP (%) | Government expenditure on tertiary education as % of GDP (%) | Government expenditure per tertiary student (PPP$) | Government expenditure per upper secondary student (PPP$) | Gross enrolment ratio, tertiary, both sexes (%) | Gross enrolment ratio, upper secondary, both sexes (%) | Internet users (per 100 people) | Percentage of enrolment in tertiary education in private institutions (%) |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| **0** | 1999 | Albania | 9.68246 | 1.172813e+10 | 3.37669 | 0.70164 | 0.77585 | 1275.984863 | 393.93927 | 14.805040 | 42.998322 | 0.081437 | -7.233222 |
| **237** | 2000 | Albania | 10.13703 | 1.280375e+10 | 3.28719 | 0.70164 | 0.77585 | 1275.984863 | 393.93927 | 15.603730 | 43.697090 | 0.114097 | -5.361620 |
| **475** | 2001 | Albania | 10.58193 | 1.408616e+10 | 3.34271 | 0.70164 | 0.77585 | 1275.984863 | 393.93927 | 15.974960 | 45.356331 | 0.325798 | -3.490018 |
| **712** | 2002 | Albania | 9.88692 | 1.486245e+10 | 3.05522 | 0.70164 | 0.77585 | 1275.984863 | 393.93927 | 16.431709 | 48.959530 | 0.390081 | -1.618415 |
| **949** | 2003 | Albania | 10.57360 | 1.597008e+10 | 3.06470 | 0.70164 | 0.77585 | 1275.984863 | 393.93927 | 16.805559 | 51.771450 | 0.971900 | 0.000000 |

# Nettoyage des données

**Suppression des lignes non pertinentes**
Exclusion des entités non reconnues par l'ONU (ex : régions, économies globales).
Résultat : 184 pays valides sur 237

**Utilisation des sets pour le filtrage**
Les ensembles facilitent la rapidité et la puissance des comparaisons, permettant une exclusion précise

**Attribution des zones géographiques**
Ajout d'une colonne « Région » associant chaque pays à zone (ex : 'Europe', 'Asie Centrale', etc.)

**Objectif**
Permettre des analyses ciblées par région pour guider la stratégie d'Academy

# Analyse des données

**Statistiques Descriptives des Indicateurs :** Résumé des Interprétations Clés

**Dépenses dans l'éducation (% du PIB)**

Moyenne : **4.7%**
Priorité : Pays avec des investissements élevés, engagement fort dans l'éducation

**RNB (PPA, en milliards de $)**

Moyenne : **581Mds $**
Priorité : pays avec un Revenu National Brut avec Parité du Pouvoir d'Achat élevé

**Ratio brut d'inscription (%)**

Secondaire : **68.6%**
Supérieur : **36.6%**
Priorité : Taux d'inscription élevés

**Utilisateurs d'internet (pour 100 pers.)**

Médiane : **38%**
Priorité : Pays avec une pénétration internet supérieure à la médiane

# Analyse des données

**Représentations visuelles univariées :** Histogrammes Clés

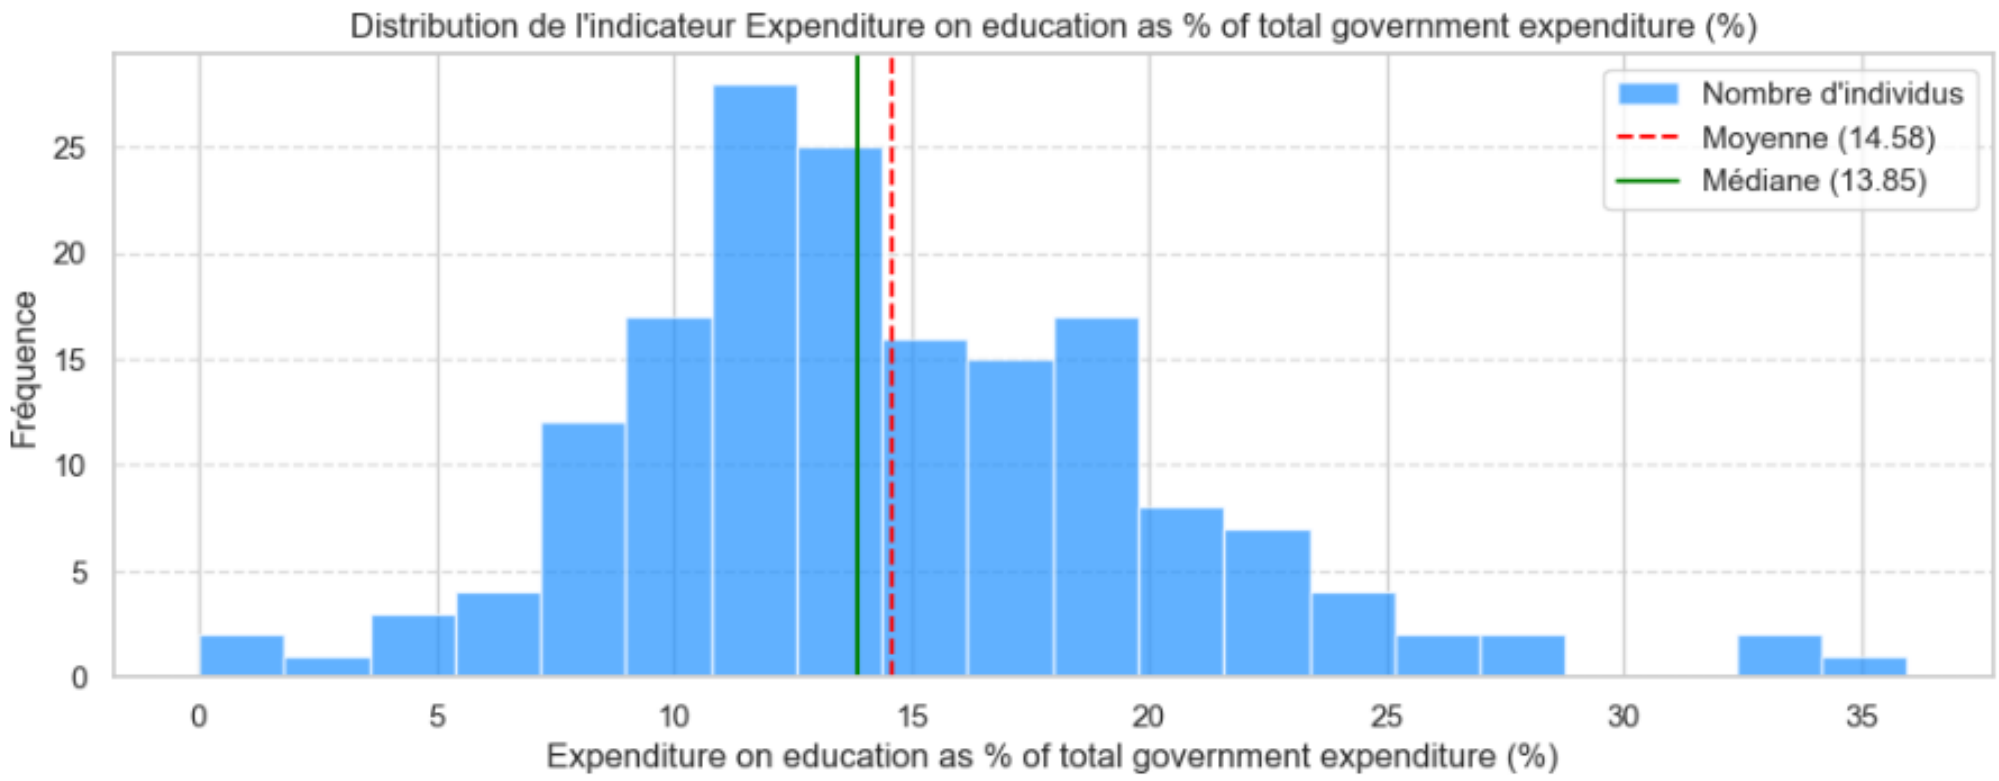

# Analyse des données

**Représentations visuelles univariées :** Histogrammes Clés

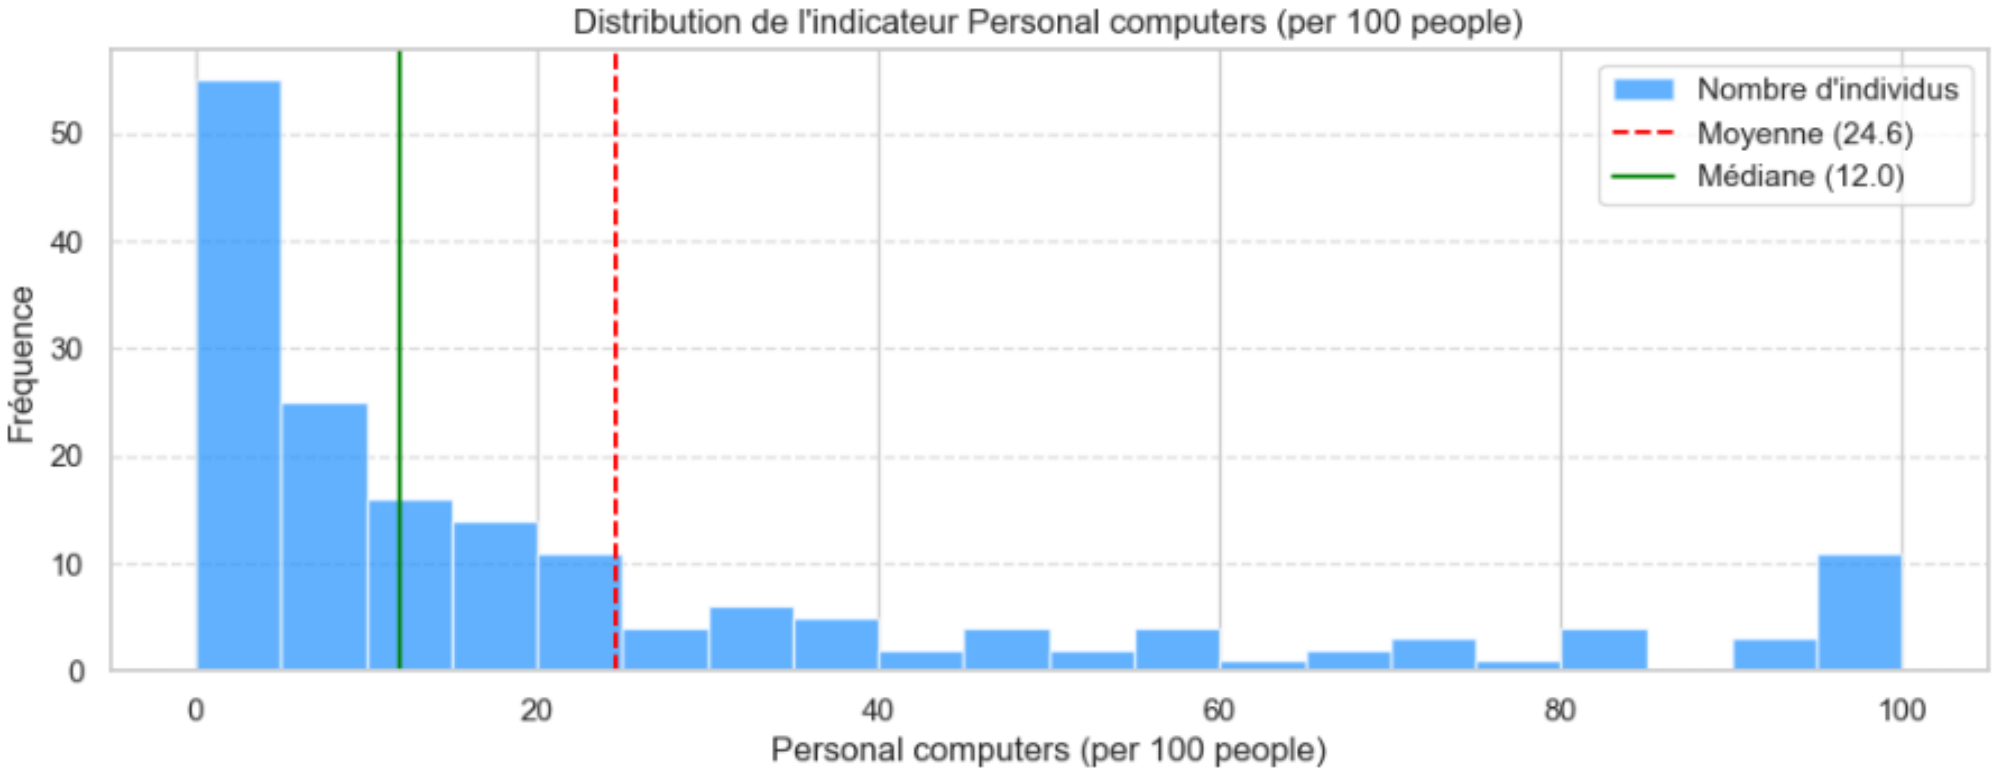

# Analyse des données

**Représentations visuelles univariées :** Taux d'inscription dans l'enseignement secondaire

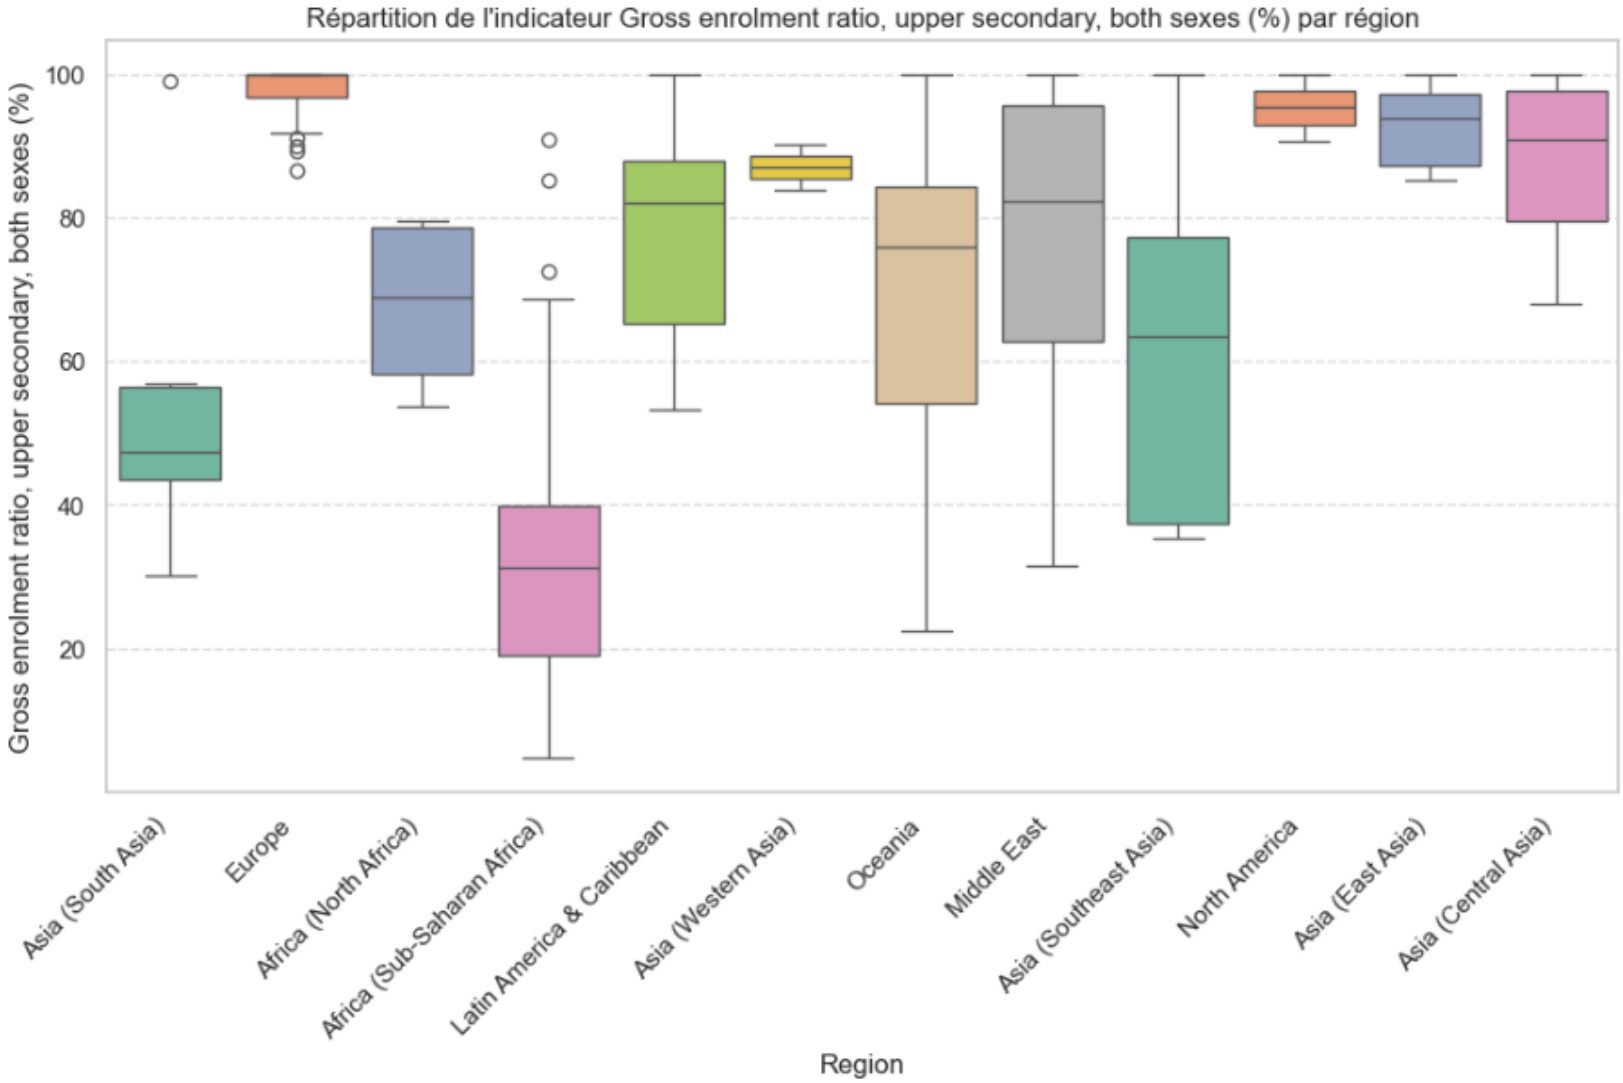


- **Focus sur les régions émergentes :** L'Amérique Latine et le Moyen Orient montrent des taux d'inscription croissants avec des inégalités internes. Ces pays pourraient bénéficier de plateformes d'apprentissage numériques adaptées.

- **Offres spécialisées pour les marchés matures :** Proposer des contenus éducatifs innovants ou avancés pour les marchés saturés comme l'Europe et l'Amérique du Nord

# Analyse des données

**Représentations visuelles univariées :** Utilisateurs d'Internet (pour 100 pers.)

- **Focus sur les marchés matures :** L'Europe, l'Amérique du Nord, et le Moyen-Orient offrent des opportunités pour des produits éducatifs avancés et interactifs, capitalisant sur leur forte connectivité.

- **Cibler les régions en transition :** Adapter les solutions pour l'Asie de l'Est, l'Amérique Latine & Caraïbes, et L'Asie de l'Ouest, où la connectivité progresse mais reste inégale entre les pays.

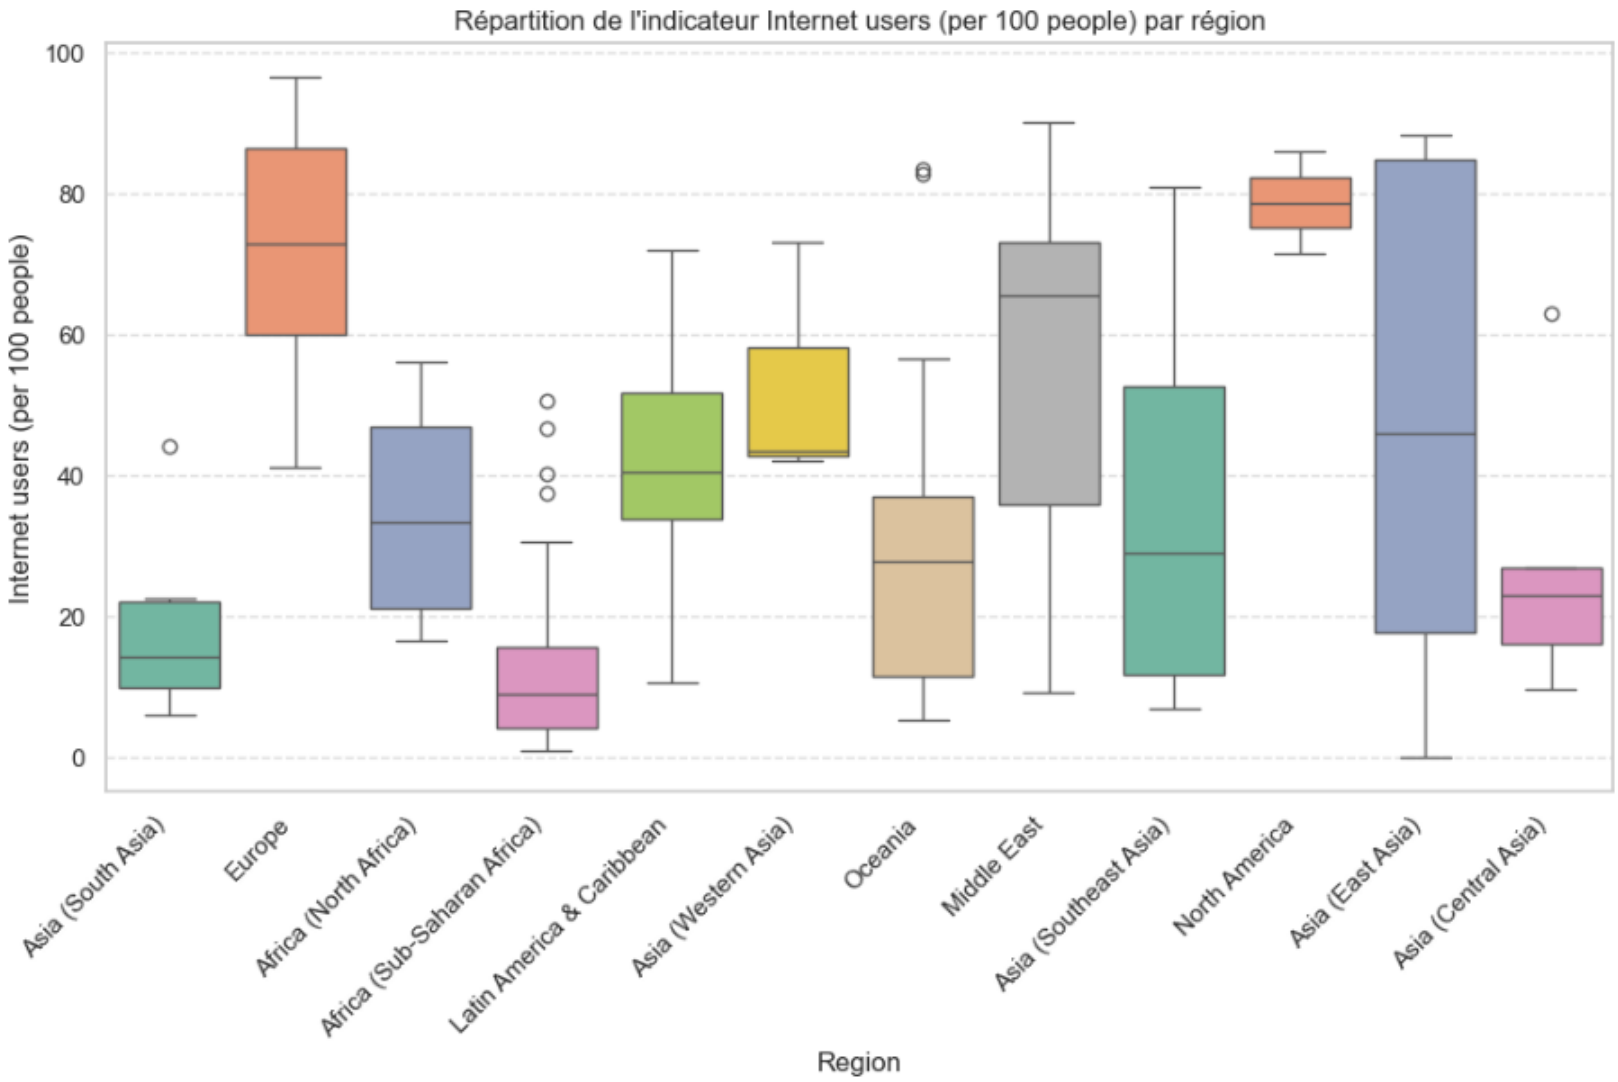

# Analyse des données

## Sélection des Régions Prioritaires

### Europe :

- Taux d'inscriptions élevés
- Adoption d'Internet (**~75%**)
- Dépenses éducatives significatives (**~5% du PIB**)

→ Marché mature pour des solutions haut de gamme

### Amérique Latine et Caraïbes :

- Taux d'inscriptions modéré
- Adoption d'internet en progression (**~40%**)
- Dépenses éducatives similaires à l'Europe (**~5% du PIB**)

→ Opportunité pour des solutions numériques abordables

### Moyen Orient :

- Taux d'inscription variés
- Adoption d'internet croissante (**~65%**)
- Dépenses éducatives modérées (**~4% du PIB**)

→ Marché émergent avec une stabilité régionale

**Autres régions :** Amérique du Nord saturée, Afrique Subsaharienne limitée par la connectivité (**~10%**), Asie marquée par les disparités internes.

# Analyse des données

**Corrélation entre indicateurs :** Matrice de corrélation entre indicateurs clés

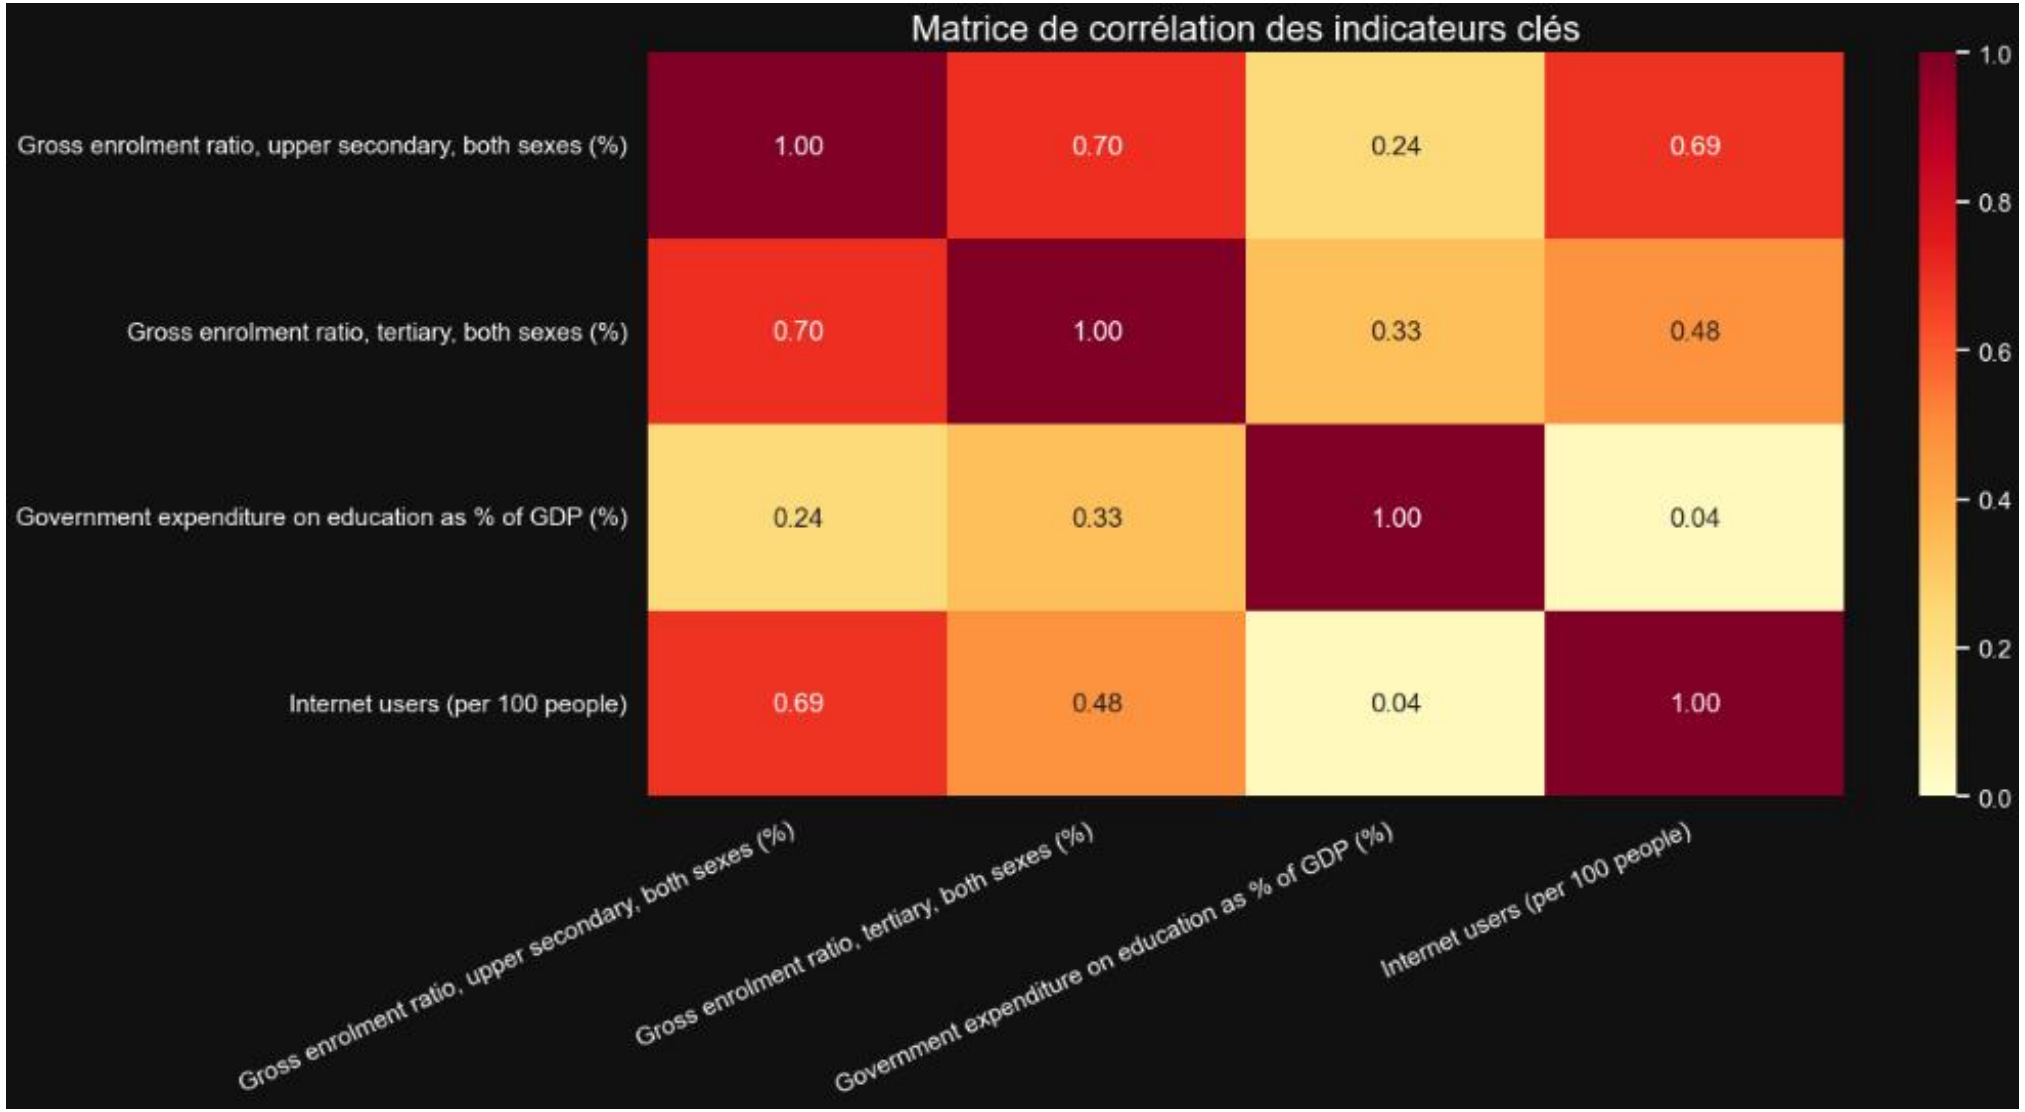

# Analyse des données

**Représentations visuelles bivariées :** Corrélation entre deux indicateurs

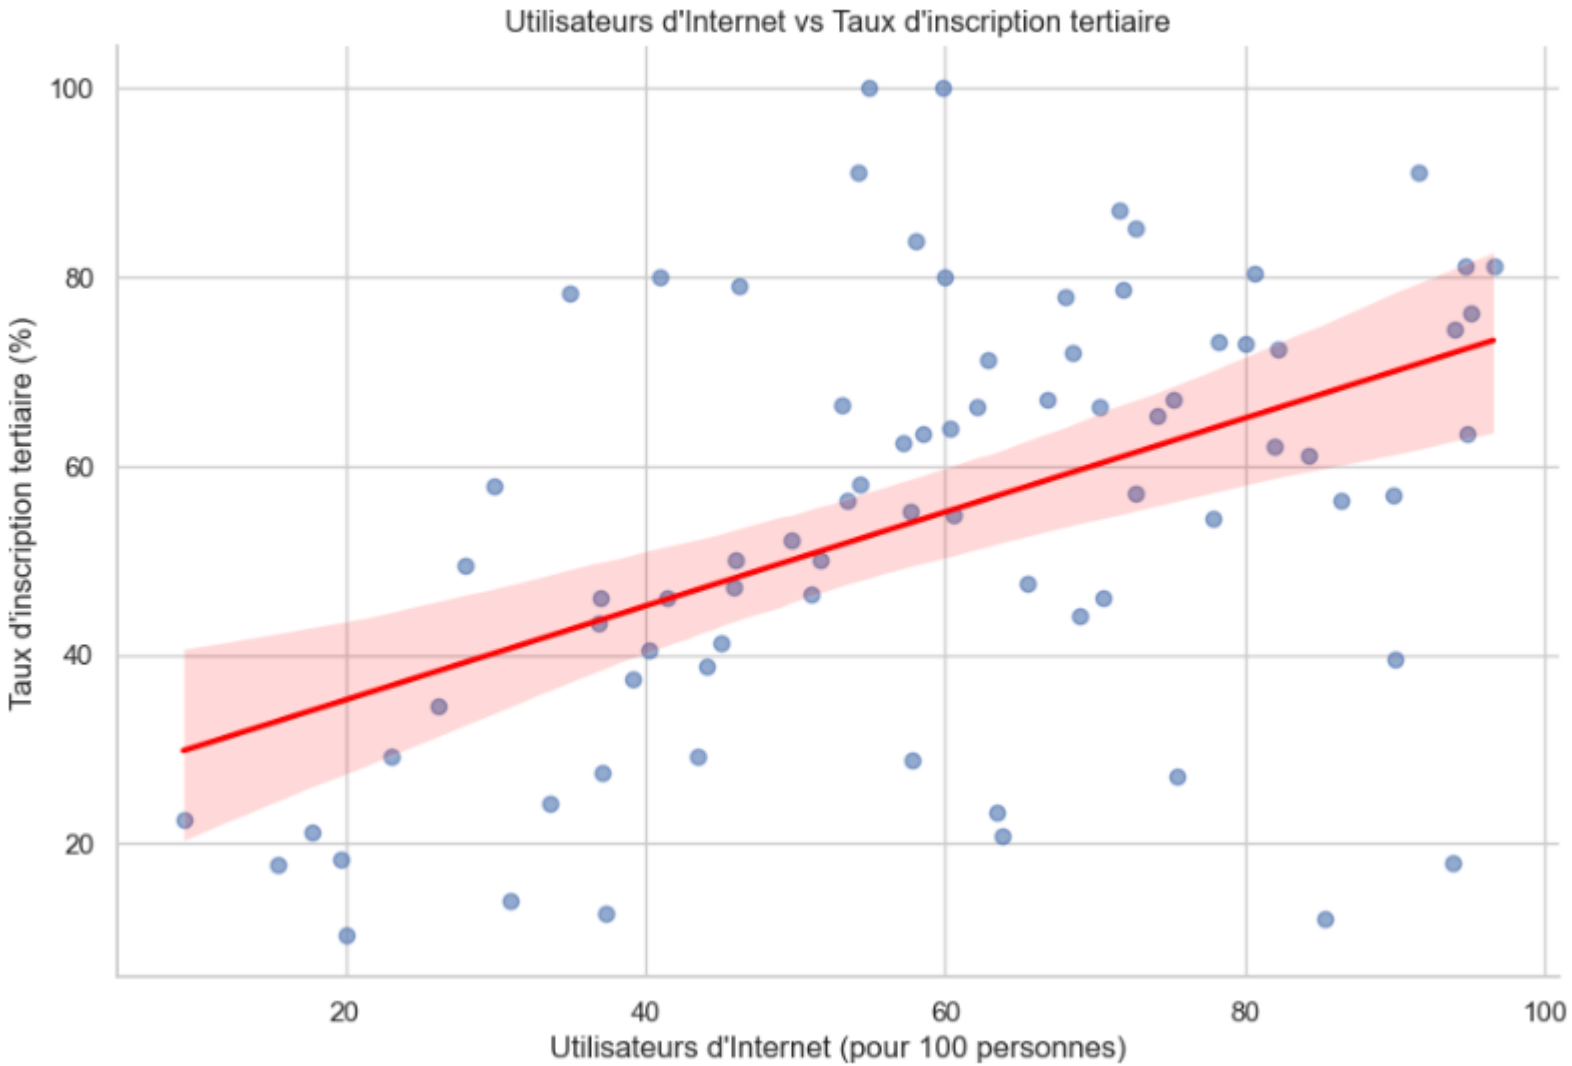


**Relation positive modérée :** La pente de la droite de régression indique qu'une augmentation de l'accès à Internet tend à accroitre l'enseignement tertiaire.

**Dispersion :** Les points montrent une variabilité autour de la droite, reflétant l'influence d'autres facteurs sur le taux d'inscription.

**Zone d'incertitude :** Les intervalles de confiance (zone rouge) sont plus larges aux extrémités, indiquant une incertitude accrue.

**Implications pour Academy :** Investir dans des régions avec une connectivité Internet en développement pourrait également stimuler l'éducation supérieure .

# Analyse des données

**Représentations visuelles bivariées :** indicateurs clés par pays pour la région Europe

**Norvège :**
- Taux d'inscription secondaire : **100%**
- Taux d'inscription universitaire : **76.12%**
- Dépenses publiques en éducation : **7.37%**
- Utilisateurs d'internet : **95.05%**

**Suède :**
- Taux d'inscription secondaire : **100%**
- Taux d'inscription universitaire : **91.07%**
- Dépenses publiques en éducation : **7.17%**
- Utilisateurs d'internet : **91.51%**

**Finlande :**
- Taux d'inscription secondaire : **100%**
- Taux d'inscription universitaire : **63.39%**
- Dépenses publiques en éducation : **7.72%**
- Utilisateurs d'internet : **94.78%**

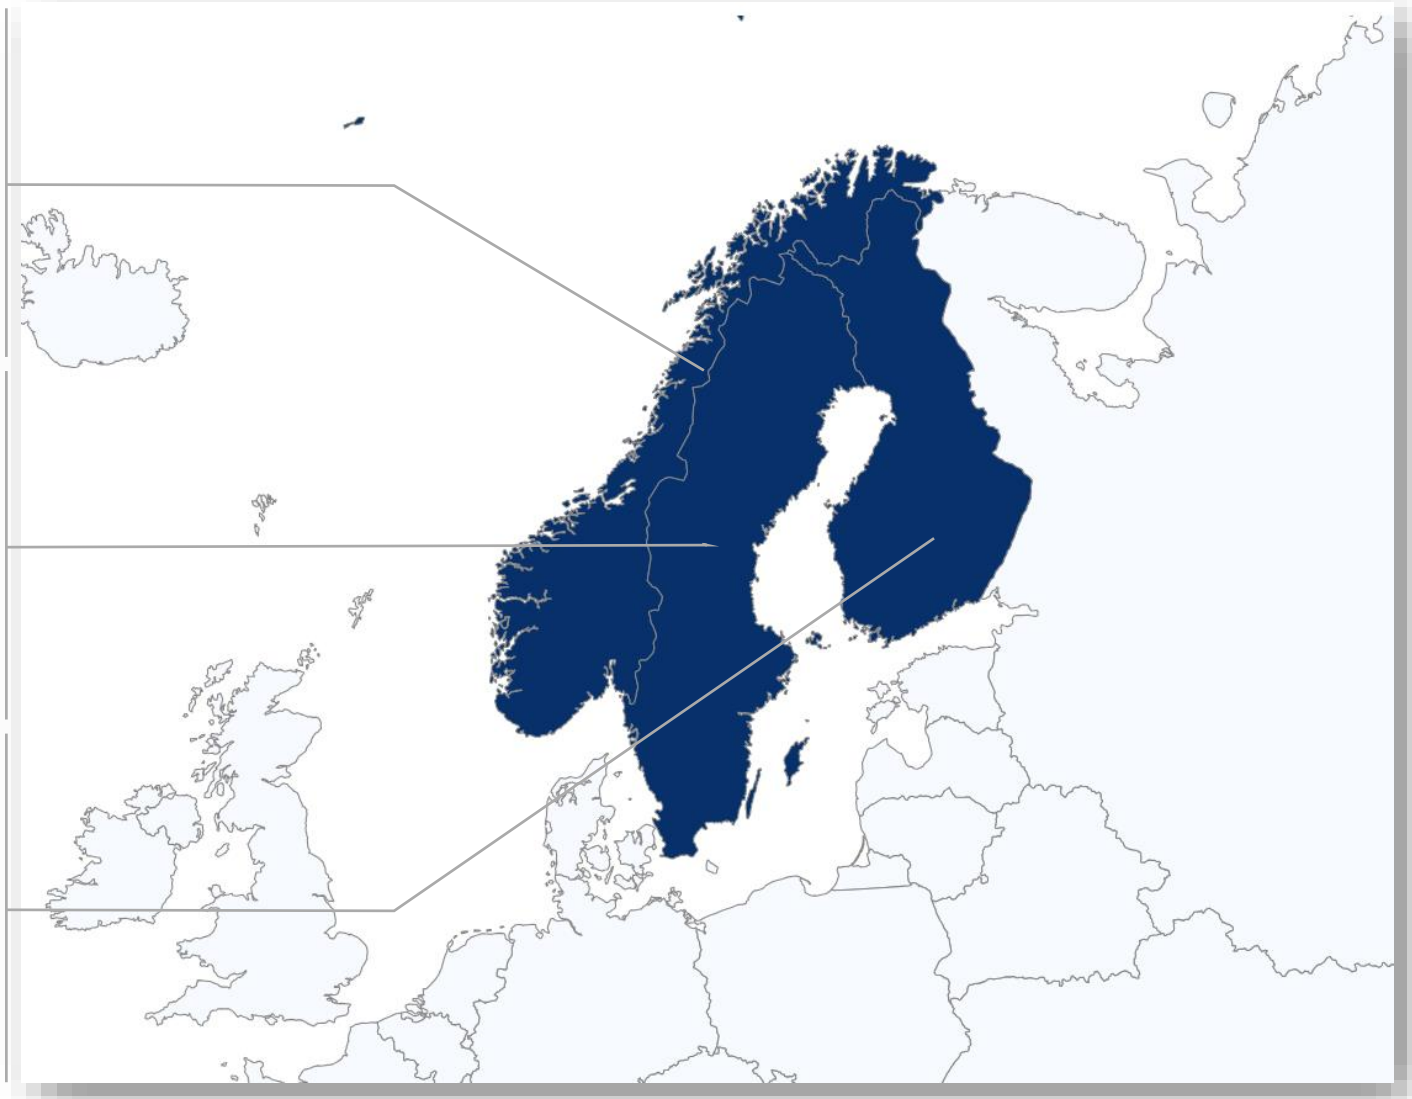

# Analyse des données

**Représentations visuelles bivariées :** indicateurs clés par pays pour la région Amérique Latine et Caraïbes

**Costa Rica :**
- Taux d'inscription secondaire : **93.5%**
- Taux d'inscription universitaire : **50.01%**
- Dépenses publiques en éducation : **6.87%**
- Utilisateurs d'internet : **45.96%**

**Brésil :**
- Taux d'inscription secondaire : **93.23%**
- Taux d'inscription universitaire : **46.45%**
- Dépenses publiques en éducation : **5.99%**
- Utilisateurs d'internet : **51.04%**

**Chili :**
- Taux d'inscription secondaire : **99.02%**
- Taux d'inscription universitaire : **83.82%**
- Dépenses publiques en éducation : **4.56%**
- Utilisateurs d'internet : **58.0%**

# Analyse des données

**Représentations visuelles bivariées :** indicateurs clés par pays pour la région Moyen Orient

**Turquie :**
- Taux d'inscription secondaire : **99.66%**
- Taux d'inscription universitaire : **66.28%**
- Dépenses publiques en éducation : **5.83%**
- Utilisateurs d'internet : **70.25%**

**Chypre :**
- Taux d'inscription secondaire : **96.77%**
- Taux d'inscription universitaire : **47.53%**
- Dépenses publiques en éducation : **6.44%**
- Utilisateurs d'internet : **65.45%**

**Israël :**
- Taux d'inscription secondaire : **95.42%**
- Taux d'inscription universitaire : **78.98%**
- Dépenses publiques en éducation : **4.77%**
- Utilisateurs d'internet : **46.25%**

# Analyse des données

**Statistiques avancées :** Analyse du taux d'inscription dans les établissements privés du secondaire par région avec le chi²

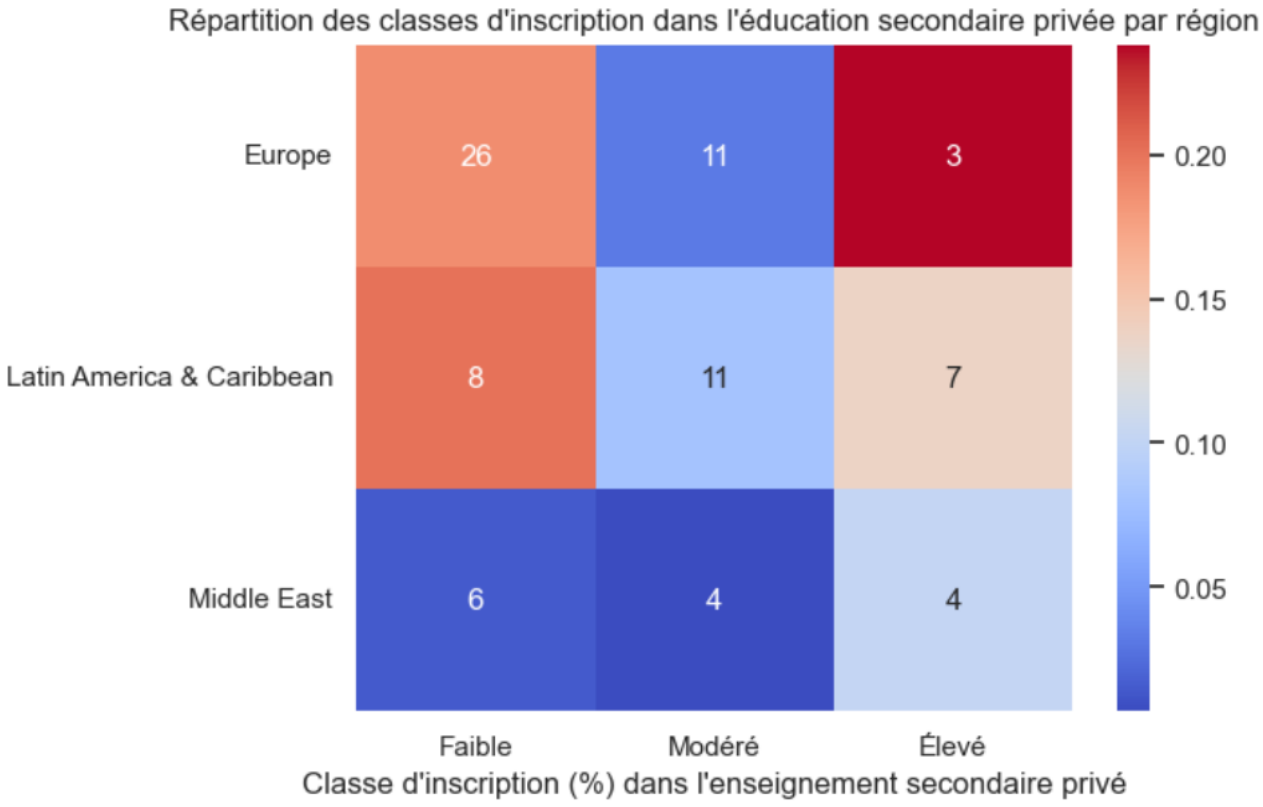


- **Objectif du test :** Évaluer l'hypothèse d'indépendance entre la région géographique et le taux d'inscription dans l'enseignement secondaire privé.

- **Interprétation des couleurs :** Couleurs froides (proche de l'attendu, indépendance faible) vs couleurs chaudes (écart fort, relation significative).

- **Résultats clés :**
  - Europe : forte concentration en 'Faible'
  - Amérique Latine : forte concentration en 'Élevé'
  - Moyen-Orient : répartition proche de l'indépendance.

- **Implications pour Academy :**
  - Europe : Stratégie axée sur le public
  - Amérique Latine : Adapter l'offre pour le privé
  - Moyen-Orient : Test des deux approches

# Analyse des données

**Analyse temporelle et prévisions :** Évolution des dépenses publiques en éducation

**Importance de l'indicateur**
Les dépenses publiques en éducation (% du PIB) reflètent l'engagement des gouvernements et le potentiel d'intégration des solutions EdTech.

**Analyse des tendances**
Identifier les pays où les investissements éducatifs sont en croissance ou stagnent pour repérer les opportunités.

**Méthodologie**
Utilisation de la régression pour comparer l'évolution des dépenses dans chaque pays et estimer les trajectoires futures.

**Impact stratégique**
Prioriser les marchés avec une dynamique d'investissement favorable pour optimiser les choix d'expansion.

# Analyse des données

## **Analyse temporelle et prévisions :** Évolution des dépenses publiques en éducation en Europe

**Tendance croissante des investissements :**
La Finlande présente une augmentation continue des dépenses publiques en éducation ($y = 0.09x – 171.02$)

**Comparaison avec la Norvège et la Suède :**
La Norvège ($y = 0.00x + 4.21$) et la Suède ($y = 0.04x – 74.45$) montrent des évolutions plus modérées.

**Engagement gouvernemental fort :**
Investissement maximal prévu en 2019, confirmant la priorité accordée à l'éducation.

**Opportunité stratégique pour Academy :**
Un marché stable et innovant, propice au développement de solutions éducatives avancées.

# Analyse des données

**Analyse temporelle et prévisions :** Évolution des dépenses publiques en éducation en Amérique Latine

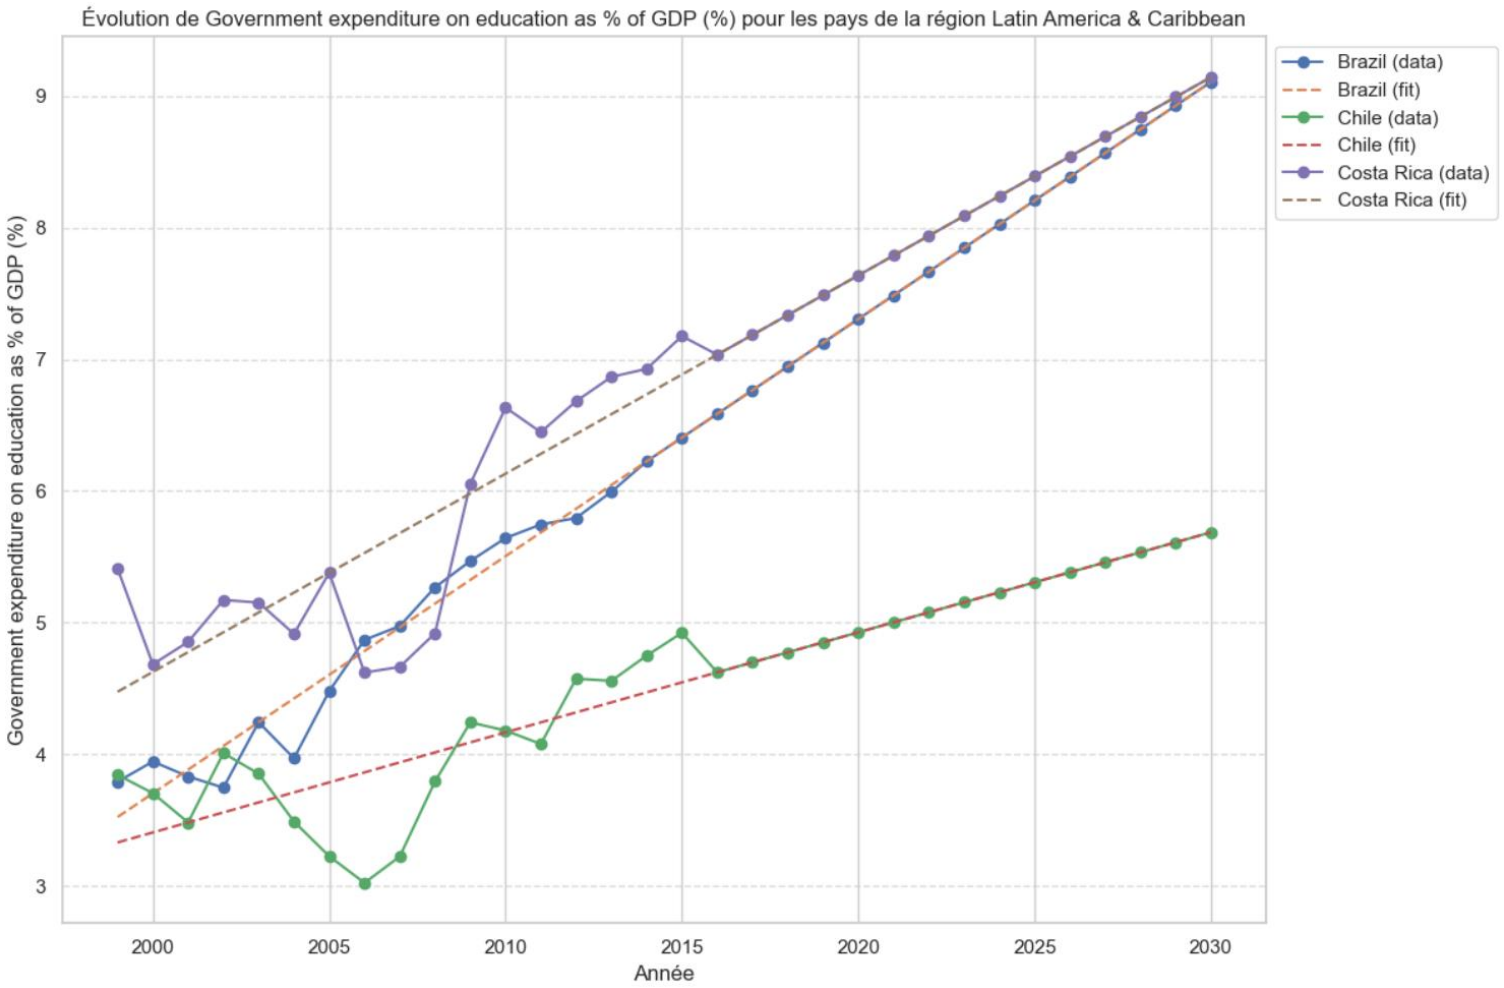


**Croissance des investissements :**
Le Brésil présente la pente de régression la plus élevée ($y = 0.18x - 356.42$), indiquant une dynamique forte et durable.

**Portée démographique :** Avec une population massive, le Brésil offre un marché éducatif vaste et prometteur pour Academy.

**Comparaison avec le Chili et le Costa Rica :**
Le Chili ($y = 0.08x – 138.53$) a une croissance plus faible, et le Costa Rica ($y = 0.15x + 296.45$) présente un potentiel limité par sa taille démographique.

**Opportunité stratégique :** Le Brésil combine une dynamique économique favorable et une demande éducative importante, en faisant un marché clé pour Academy.

# Analyse des données

**Analyse temporelle et prévisions :** Évolution des dépenses publiques en éducation au Moyen-Orient

**Croissance rapide des investissements :**
La Turquie présente la pente de régression la plus élevée ($y = 0.13x – 259.30$), indiquant une forte dynamique d'investissement.

**Portée démographique :** Avec une population bien plus grande que Chypre et Israël, la Turquie offre un marché vaste et stratégique.

**Comparaison avec Chypre et Israël :**
Chypre ($y = 0.11x – 219.73$) a un fort investissement mais une population limitée. Israël montre une tendance négative des dépenses éducatives ($y = - 0.06x + 116.71$).

**Opportunité stratégique pour Academy :**
L'engagement gouvernemental en forte progression fait de la Turquie un marché clé pour Academy.

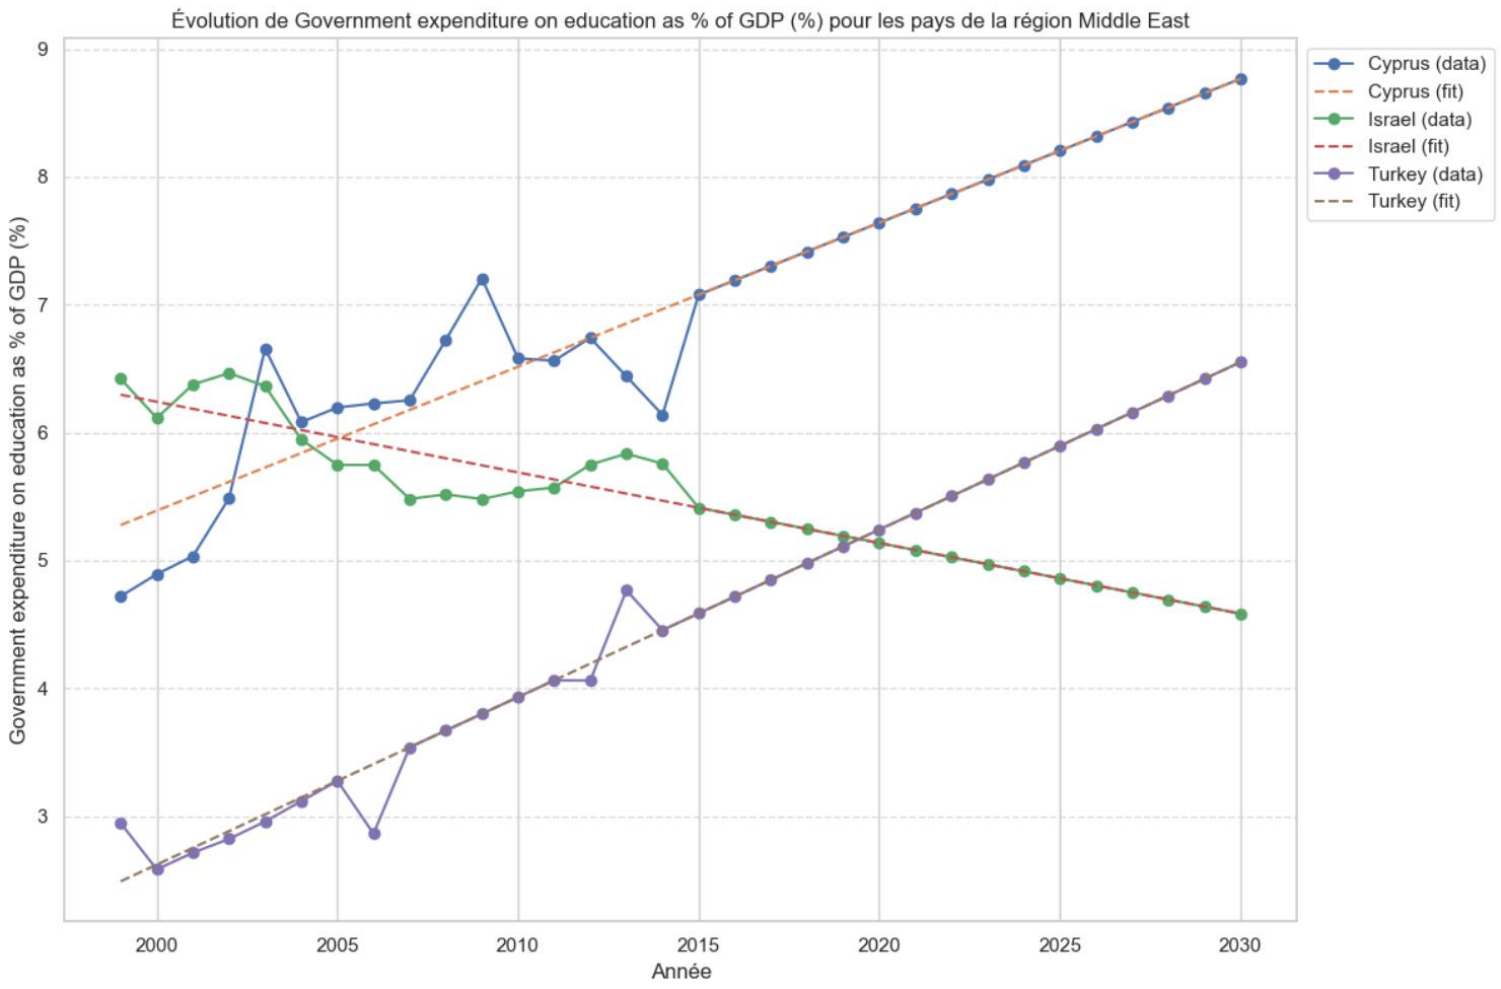

# Conclusion

**Les pays prioritaires pour Academy :** Pourquoi la Finlande, le Brésil et la Turquie ?

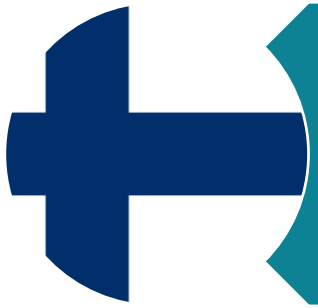

**Finlande, un leader éducatif :** Croissance continue des investissements, marché stable et hautement technologique.

**Brésil, un marché vaste et dynamique :** Investissements en forte hausse, démographie importante et besoin accru en EdTech.

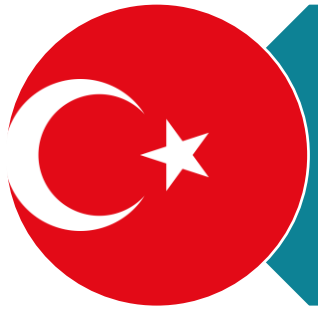

**Turquie, une expansion éducative rapide :** Croissance rapide des investissements, fort potentiel démographique et position stratégique.

# Conclusion

**Conclusion Générale & Prochaines Étapes :** Stratégie d'expansion d'Academy

- **Sélection stratégique des pays :** Finlande, Brésil et Turquie offrent des opportunités optimales grâce à leur engagement éducatif et leur besoin en solutions EdTech.
- **Diversification régionale :** Europe (Finlande), Amérique Latine (Brésil) et Moyen-Orient (Turquie) assurent une implantation variée et complémentaire.
- **Opportunités clés :** Investissements en hausse, large public cible et adoption croissante des technologies éducatives.
- **Prochaines étapes :** Développement de collaborations locales, adaptation des contenus éducatifs et maximisation de l'impact.

Source : www.dreamstime.com

# Merci